Clasificación automática de enfermedades foliares en caña de azúcar mediante visión por computador, PlantCV y Random Forest

[a] *Alvarez Lopez, Deibys Duvian;* [b]*Calle Urrego Edith Alejandra;* [c]*Londoño Uribe Juan Diego*

Escuela de Ciencias Aplicadas e Ingeniería, Universidad Eafit, Medellín, Colombia

[a]*Ingeniería agronómica, EAFIT, Medellín, Colombia, ddalvarezl@eafit.edu.co*

[b]*Ingeniería agronómica, EAFIT, Medellín, Colombia, eacalleu@eafit.edu.co*

[c]*Ingeniería agronómica, EAFIT, Medellín, Colombia, jdlondonou@eafit.edu.co*

Resumen

Las enfermedades foliares representan una de las principales limitantes fitosanitarias en la producción de caña de azúcar debido a las pérdidas fisiológicas y productivas asociadas a la reducción de la actividad fotosintética y el deterioro del tejido vegetal. Tradicionalmente, la identificación de síntomas se realiza mediante inspección visual en campo, procedimiento que depende de la experiencia del evaluador y presenta limitaciones relacionadas con subjetividad y capacidad operativa. En este estudio se desarrolló un sistema automatizado de clasificación de enfermedades foliares en caña de azúcar mediante visión por computador, extracción de características con PlantCV y clasificación supervisada utilizando Random Forest.

El dataset estuvo conformado por imágenes RGB organizadas en cuatro categorías fitosanitarias: Amarillamiento, Asintomáticas, *Colletotrichosis* prueba y *Puccinia* prueba. El flujo metodológico incluyó segmentación automática de hoja, detección de zonas afectadas mediante espacios de color HSV y LAB, extracción de variables morfológicas y cromáticas, y entrenamiento de un modelo Random Forest para clasificación de síntomas foliares.

El modelo alcanzó un accuracy general de 0.76, un OOB Score de 0.7887 y validación cruzada promedio 0.8057. Asimismo, presentó un precision macro promedio de 0.76, recall macro de 0.76 y F1-score macro de 0.76. La clase Asintomáticas presentó el mejor desempeño general, mientras que *Colletotrichosis* prueba mostró la menor capacidad de clasificación debido a similitudes visuales con otras afecciones. Los resultados evidencian el potencial de integrar procesamiento digital de imágenes y aprendizaje automático para el monitoreo fitosanitario automatizado en sistemas de agricultura de precisión.

Palabras clave: caña de azúcar, enfermedades foliares, segmentación, PlantCV, Random Forest, visión por computador, agricultura de precisión.

1. Introducción

La caña de azúcar (*Saccharum officinarum* L.) constituye uno de los cultivos agrícolas de mayor relevancia económica a nivel mundial, con áreas productivas en más de 120 países, debido a su importancia en la producción de azúcar, etanol y subproductos agroindustriales. En Colombia, la caña de azúcar se concentra principalmente en el valle geográfico del río Cauca, particularmente en el departamento del Valle del Cauca, donde los rendimientos frecuentemente superan las 100 t/ha (Cortés et al., 2024). Sin embargo, el cultivo se encuentra expuesto a múltiples enfermedades foliares capaces de afectar procesos fisiológicos esenciales como fotosíntesis, respiración y translocación de nutrientes, generando disminuciones significativas en rendimiento y calidad industrial (Rott et al., 2021).

Entre las principales problemáticas fitosanitarias asociadas a la caña de azúcar se encuentran enfermedades caracterizadas por amarillamiento foliar, necrosis, manchas y alteraciones pigmentarias, las cuales pueden dificultar el monitoreo temprano debido a la similitud visual entre síntomas. Tradicionalmente, la identificación de estas enfermedades se realiza mediante inspección visual en campo, metodología que depende considerablemente de la experiencia técnica del evaluador y puede verse afectada por subjetividad, fatiga visual y limitaciones operativas en sistemas agrícolas extensivos (Saleem et al., 2022).

En los últimos años, la agricultura de precisión ha incorporado herramientas basadas en visión por computador y aprendizaje automático con el objetivo de automatizar procesos de monitoreo vegetal. Estas tecnologías permiten analizar imágenes digitales y extraer variables cuantitativas relacionadas con color, textura, morfología y patrones espaciales asociados al estado fisiológico de las plantas (Liu et al., 2023).

El procesamiento digital de imágenes ha demostrado alta eficiencia para detectar síntomas relacionados con clorosis, necrosis y pérdida de pigmentación. Particularmente, los espacios de color HSV y LAB permiten separar de forma más eficiente hoja, fondo y regiones afectadas bajo condiciones variables de iluminación, facilitando procesos de segmentación automática (Zhang et al., 2022).

Dentro de las herramientas utilizadas para fenotipado vegetal, PlantCV se ha consolidado como una biblioteca especializada en extracción automatizada de variables morfológicas y cromáticas a partir de imágenes vegetales. Esta plataforma permite transformar información visual en variables cuantitativas útiles para modelos de clasificación supervisada (Fahlgren et al., 2021).

Por otra parte, Random Forest se ha convertido en uno de los algoritmos más utilizados en agricultura digital debido a su robustez estadística, capacidad para manejar variables no lineales y resistencia frente al sobreajuste. El algoritmo combina múltiples árboles de decisión para generar modelos de clasificación más estables y eficientes (Liu et al., 2023).

A partir de estas bases, el objetivo del presente estudio fue desarrollar un sistema automatizado para clasificación de enfermedades foliares en caña de azúcar utilizando procesamiento digital de

imágenes, extracción de características mediante PlantCV y clasificación supervisada con Random Forest.

2. Materiales y métodos

2.1 Dataset

El dataset estuvo compuesto por imágenes RGB de hojas de caña de azúcar organizadas en carpetas según la categoría fitosanitaria correspondiente. Las clases utilizadas fueron: Amarillamiento, asintomáticas, colletotrichosis prueba y Puccinia prueba.

Cada carpeta representó una clase independiente utilizada posteriormente como variable objetivo dentro del modelo de clasificación.

Las imágenes presentaron variabilidad en iluminación, orientación foliar, intensidad de síntomas y tamaño de hoja, permitiendo representar condiciones reales de captura. Para evitar desbalance entre categorías, se utilizaron aproximadamente 70 imágenes por clase dentro del conjunto de evaluación final.

2.2 Segmentación de imágenes

El procesamiento de imágenes fue desarrollado utilizando Python y bibliotecas de visión por computador. Inicialmente, las imágenes RGB ((Red, Green, Blue)) fueron convertidas hacia los espacios de color HSV (Tono, Saturación, Valor) y LAB (Luminosidad, verde-rojo, azul-amarillo) con el objetivo de mejorar la diferenciación entre hoja, enfermedad y fondo.

Posteriormente, se implementó una segmentación basada en GrabCut y operaciones morfológicas. El procedimiento incluyó:

- Conversión RGB-HSV.
- Conversión RGB-LAB.
- Aplicación de umbrales adaptativos.
- Operaciones morfológicas de closing y opening.
- Eliminación de objetos pequeños.
- Relleno de huecos internos.

Las regiones asociadas a enfermedad fueron detectadas mediante diferencias cromáticas relacionadas con pérdida de pigmentación verde, necrosis y alteraciones de brillo y saturación.

2.3 Extracción de características

La extracción de variables fue realizada mediante PlantCV y operaciones matriciales desarrolladas en Python.

Las principales variables obtenidas fueron: Área total de hoja, área afectada, Porcentaje de afectación, promedios RGB, variables HSV, variables LAB, índices ExG (Exceso de Verde), ExR (Exceso de Rojo), y NGRDI (Diferencia Verde-Rojo Normalizado) y desviaciones estándar cromáticas.

Adicionalmente, se calcularon variables de textura mediante matrices de coocurrencia de niveles de gris (GLCM), incluyendo contraste, homogeneidad, energía y correlación. Estas variables permitieron describir patrones espaciales y texturales asociados a lesiones foliares, necrosis y heterogeneidad visual presentes en las hojas afectadas.

Cada imagen fue transformada en una fila de un dataset tabular donde las columnas correspondieron a las variables extraídas y la etiqueta de salida correspondió a la enfermedad asociada.

2.4 Modelo de clasificación

El modelo Random Forest fue implementado utilizando Scikit-learn. El dataset fue dividido en 70% para entrenamiento y 30% para validación.

Las variables relacionadas directamente con área enferma y porcentaje de enfermedad no fueron utilizadas durante el entrenamiento del modelo, con el fin de evitar dependencia excesiva de severidad y favorecer el aprendizaje de patrones cromáticos, morfológicos y texturales asociados a cada enfermedad foliar.

El modelo fue configurado utilizando 300 árboles de decisión, balanceo automático de clases y validación interna mediante OOB Score (Out-of-Bag Score), permitiendo estimar el desempeño del clasificador utilizando muestras no empleadas durante el entrenamiento de cada árbol.

Las métricas utilizadas para evaluación fueron accuracy, precision, recall, F1-score y matriz de confusión.

Adicionalmente, el desempeño del modelo fue evaluado mediante validación cruzada estratificada de 5 particiones (Stratified K-Fold Cross Validation), con el objetivo de estimar la estabilidad y capacidad de generalización del clasificador sobre diferentes subconjuntos del dataset.

3. Resultados y discusión

La metodología desarrollada permitió segmentar adecuadamente las hojas de caña de azúcar en la mayoría de las imágenes procesadas. La combinación de los espacios de color HSV y LAB junto con el algoritmo GrabCut, las operaciones morfológicas y la extracción de variables fenotípicas permitió diferenciar de forma consistente hoja, fondo y tejido afectado, reduciendo considerablemente el ruido asociado a sombras, reflejos y variaciones de iluminación presentes en las imágenes del dataset.

La incorporación de variables de textura derivadas de matrices de coocurrencia de niveles de gris (GLCM) aportó información adicional sobre la distribución espacial de los patrones foliares, especialmente en clases donde los síntomas presentan manchas, necrosis o cambios heterogéneos en la superficie de la hoja. Esto fortaleció la capacidad del modelo para discriminar categorías con apariencia cromática parcialmente similar.

Las categorías *Colletotrichosis* prueba y *Puccinia* prueba presentaron síntomas visualmente más contrastantes debido a la presencia de lesiones necróticas y manchas oscuras distribuidas sobre el tejido foliar. En contraste, la categoría Amarillamiento presentó síntomas más homogéneos relacionados principalmente con pérdida progresiva de pigmentación verde, mientras que las hojas Asintomáticas mostraron mayor uniformidad cromática y menor variabilidad interna.

El modelo Random Forest obtuvo un OOB Score de 0.7887, indicando una capacidad de generalización moderadamente alta utilizando muestras fuera de bolsa. Adicionalmente, la validación cruzada estratificada mostró accuracies de 0.8214, 0.8036, 0.8036, 0.7636 y 0.8364, con un promedio de 0.8057, evidenciando un comportamiento estable del modelo entre particiones del dataset.

En el conjunto de prueba, conformado por 84 imágenes, el modelo alcanzó una exactitud general de 0.76, con una precisión macro de 0.77, recall macro de 0.76 y F1-score macro de 0.76. Estos resultados indican que el modelo logró identificar patrones asociados a las diferentes enfermedades foliares evaluadas, aunque todavía presenta limitaciones en clases con alta similitud visual.

La categoría Amarillamiento presentó una precisión de 0.80, recall de 0.76 y F1-score de 0.78, lo que indica un reconocimiento sólido de esta clase. La categoría Asintomáticas mostró el mejor comportamiento general, con precisión de 0.84, recall de 0.76 y F1-score de 0.80, reflejando que las hojas sanas mantuvieron patrones cromáticos y texturales suficientemente uniformes para ser diferenciadas con buena eficacia.

Por su parte, *Colletotrichosis* prueba obtuvo una precisión de 0.71, recall de 0.71 y F1-score de 0.71, lo que sugiere un desempeño equilibrado, pero todavía limitado por la similitud visual con otras afecciones. La categoría *Puccinia* prueba alcanzó una precisión de 0.71, recall de 0.81 y F1-score de 0.76, mostrando una mayor capacidad de recuperación de casos reales, aunque con cierta confusión entre síntomas visualmente cercanos.

La matriz de confusión mostró un comportamiento consistente del modelo Random Forest en las cuatro categorías evaluadas. La diagonal principal presentó 64 clasificaciones correctas sobre un

total de 84 muestras evaluadas, alcanzando una exactitud aproximada del 76%, mientras que los errores de clasificación se concentraron principalmente entre enfermedades con síntomas visualmente similares.

La categoría Amarillamiento presentó 16 clasificaciones correctas, mientras que algunas imágenes fueron confundidas con *Puccinia* y *Colletotrichosis*. Este comportamiento puede relacionarse con la presencia de pérdida heterogénea de pigmentación y regiones parcialmente necróticas en hojas con estados avanzados de afectación.

La categoría Asintomáticas también obtuvo 16 aciertos, mostrando una adecuada diferenciación de hojas sanas. Sin embargo, algunas imágenes fueron clasificadas erróneamente como *Puccinia*, posiblemente debido a variaciones naturales de iluminación, sombras o irregularidades superficiales detectadas como síntomas foliares.

En *Colletotrichosis* prueba se registraron 15 clasificaciones correctas. Las principales confusiones ocurrieron con Amarillamiento y Asintomáticas, lo que sugiere que ciertas lesiones necróticas compartieron patrones cromáticos similares relacionados con disminución del contenido de clorofila y heterogeneidad visual.

La categoría *Puccinia* prueba presentó el mejor desempeño general con 17 aciertos. No obstante, algunas imágenes fueron confundidas con *Colletotrichosis* debido a similitudes texturales y distribución espacial de lesiones necróticas sobre la superficie foliar.

En total, el modelo obtuvo 64 clasificaciones correctas y 20 errores sobre 84 imágenes evaluadas. En general, los errores observados en la matriz de confusión presentaron coherencia biológica y visual, ya que las principales confusiones ocurrieron entre enfermedades con síntomas cromáticos y texturales parcialmente similares. Esto indica que el modelo logró aprender patrones relevantes asociados a las características visuales reales de las enfermedades foliares evaluadas.

El análisis de importancia de variables mostró que las características más relevantes fueron area_hoja, pcv_lab_b_mean, area_sana, H_mean, LAB_B_mean, G_mean, L_mean, GLCM_energy, V_mean, NGRDI_mean, calidad_segmentacion, G_std, porcentaje_sano, S_std y ExR_mean. En particular, la presencia de GLCM_energy dentro de las variables más importantes confirma que la textura aportó capacidad adicional de discriminación, mientras que las variables asociadas a color y área reflejan la sensibilidad del modelo frente a cambios en pigmentación, extensión del daño y homogeneidad del tejido.

Los resultados obtenidos coinciden con investigaciones recientes que destacan el potencial de la visión por computador para monitoreo fitosanitario automatizado en cultivos agrícolas (Saleem et al., 2022). Asimismo, los resultados corroboran que Random Forest representa un algoritmo robusto para clasificación agrícola debido a su capacidad para manejar datasets con alta variabilidad visual y relaciones no lineales entre variables (Liu et al., 2023).

Los resultados obtenidos muestran que la integración de visión por computador, PlantCV, variables cromáticas, morfológicas y texturales, junto con Random Forest, constituye una estrategia efectiva para la clasificación automática de enfermedades foliares en caña de azúcar.

Desde el punto de vista agronómico, la metodología desarrollada representa una alternativa viable para sistemas automatizados de monitoreo fitosanitario en caña de azúcar. La integración entre segmentación digital, extracción fenotípica y aprendizaje automático permite reducir dependencia de evaluaciones manuales y facilita la generación de diagnósticos rápidos en procesos de agricultura de precisión,

4. Conclusiones

La metodología desarrollada permitió implementar un sistema automatizado de clasificación de enfermedades foliares en caña de azúcar mediante visión por computador, PlantCV y Random Forest.

La segmentación basada en espacios de color HSV y LAB permitió diferenciar adecuadamente hoja, enfermedad y fondo en la mayoría de las imágenes procesadas, mejorando calidad de las máscaras mediante operaciones morfológicas y reducción de ruido.

El modelo Random Forest alcanzó un accuracy de prueba de 0.76, un OOB Score de 0.7887 y una validación cruzada promedio de 0.8057, evidenciando una mejora en la estabilidad y capacidad de generalización del sistema.

La categoría Asintomáticas presentó el mejor desempeño general con un F1-score de 0.80, mientras que *Colletotrichosis* prueba mostró un desempeño más moderado con F1-score de 0.71.

Las variables más relevantes incluyeron características de área, color, pigmentación y textura, destacándose GLCM_energy como un indicador importante para la discriminación de síntomas foliares.

Finalmente, los resultados evidencian el potencial de integrar procesamiento digital de imágenes y aprendizaje automático como herramientas de apoyo para sistemas de agricultura de precisión y monitoreo fitosanitario automatizado en cultivos de caña de azúcar.

Referencias

- Cortés Betancourt, E., Chica Ramírez, H.A., & Peña Quiñones, A.J. (2024). Clima y productividad de la caña de azúcar en el valle del río Cauca (Cenicaña).

- Fahlgren, N., Feldman, M., Gehan, M. A., Wilson, M. S., Shyu, C., Bryant, D. W., Hill, S. T., McEntee, C. J., Warnasooriya, S. N., Kumar, I., Ficor, T., Turnipseed, S. B., Gilbert, K. B., Brutnell, T. P., & Baxter, I. (2021). A versatile phenotyping system and analytics platform reveals diverse temporal responses to water availability in Setaria. *Plant Physiology, 181*(4), 1489–1506. https://doi.org/10.1093/plphys/kiaa001
- Liu, Y., Chen, S., Zhang, H., & Wang, X. (2023). Machine learning-based crop disease recognition using image processing and Random Forest algorithms. *Computers and Electronics in Agriculture, 206*, 107663. https://doi.org/10.1016/j.compag.2023.107663
- Rott, P., Bailey, R. A., Comstock, J. C., Croft, B. J., & Saumtally, S. (2021). A guide to sugarcane diseases. *CIRAD and ISSCT*, 2, 1–339.
- Saleem, M. H., Potgieter, J., & Arif, K. M. (2022). Plant disease detection and classification by deep learning. *Plants, 11*(4), 468. https://doi.org/10.3390/plants11040468
- Zhang, Y., Wang, S., Ji, G., & Phillips, P. (2022). Plant disease recognition based on plant leaf image. *Journal of Ambient Intelligence and Humanized Computing, 13*, 1–14. https://doi.org/10.1007/s12652-021-03198-2